

**Disciplina: IA – Inteligência Artificial**

**Professor da Disciplina: Dr. Renato José Sassi**

---

**Aluno: (Doutorando) Juliano da Silva Ignacio**

**Professor Orientador: Dr. Alessandro Melo Deana**



---

## **A IMPORTÂNCIA DO BIAS E DA VARIÂNCIA EM MODELOS PREDITIVOS**



## BIAS – o viés *ESTATÍSTICO*


Avaliando se a MEDIANA das amostras é um estimador com ou sem VIÉS (bias) da mediana da população.



UNBIASED

## BIAS – o viés *ESTATÍSTICO*

É a diferença entre a previsão esperada de um modelo e o valor correto que está tentando prever.




## VARIÂNCIA – a dispersão ESTATÍSTICA

Indica "o quão longe" em geral os seus valores se encontram do valor esperado




*SEM VARIÂNCIA*

*(sempre o mesmo valor)*



*COM BAIXA VARIÂNCIA*



*COM ALTA VARIÂNCIA*


## BIAS x VARIÂNCIA

Resumindo...

...este deve ser o entendimento *estatístico* desses dois fenômenos.



O **BIAS** é o *“ajuste de mira”* de um alvo...

BAIXA  
VARIÂNCIA




BAIXO  
BIAS

ALTA  
VARIÂNCIA




ALTO  
BIAS



## BIAS x VARIÂNCIA

O BIAS é como o  
“*ajuste de mira*”  
de um alvo...

SE...  
...a distância **bias** for  
considerada na “*equação*”  
**para acertar o alvo**,  
procura-se “*mirar*”  
no ponto **x**  
descontando-se o **bias**!







## MODELOS PREDITIVOS

Verificando a importância da compreensão de **Bias** e **Variância** para criar melhores modelos.

Dados de peso e altura de ratos.



OBJETIVO: **PREVER** a altura de um novo rato através do seu peso...





...buscando descobrir a **equação exata** da relação peso e altura.

## MODELOS PREDITIVOS

Usando métodos de Aprendizagem de Máquina.

Dividir os dados em dois conjuntos:

- Conjunto de Treinamento
- Conjunto de Teste






## MODELOS PREDITIVOS


Usando o [Conjunto de Treinamento](#).

Usando o algoritmo de Regressão Linear.



Aplicando este algoritmo o ajuste aos dados gera uma **reta** (um modelo, uma hipótese).


Não importa o **ajuste** que se faça, uma reta nunca será uma curva.



Essa dificuldade do algoritmo aplicado chegar na equação exata é o **BIAS**!



## MODELOS PREDITIVOS

Aplicando outro algoritmo (polinomial) ao [Conjunto de Treinamento](#).



O algoritmo gera uma linha sinuosa que passa exatamente por todos os pontos reais do [Conjunto de Treinamento](#), portanto, apresenta um baixíssimo **BIAS**.


**Comparação:** calcula-se a soma dos quadrados das distâncias da linha gerada até os pontos dados.





## MODELOS PREDITIVOS

Usando agora o **Conjunto de Teste**.

Os modelos foram gerados através dos dados do **Conjunto de Treinamento**, porém, deve-se verificar estes modelos junto aos dados do **Conjunto de Teste**.





**Comparação:** calcula-se a soma dos quadrados das distâncias da linha gerada até os pontos dados.



## MODELOS PREDITIVOS



Identificando a **VARIÂNCIA**.



A diferença entre os ajustes de um mesmo modelo com diferentes conjuntos de dados é a **VARIÂNCIA**.



Por conta do ajuste **excelente** no **Conjunto de Treinamento**, **mas não** no **Conjunto de Teste**, isto demonstra que está havendo **OVERFIT**.

## ANÁLISE COMPARATIVA BIAS-VARIÂNCIA



BAIXO BIAS

ALTA VARIÂNCIA





ALTO BIAS

BAIXA VARIÂNCIA

## ALGORITMO IDEAL

Em Aprendizagem de Máquina, o **algoritmo ideal** deve apresentar um **BAIXO BIAS** e conseguir aproximar o modelo o máximo possível da **equação exata** e, apresentar **BAIXA VARIÂNCIA** para gerar previsões consistentes entre **diferentes** conjuntos de dados.

BIAS  
INDUTIVO




Isto é conhecido como ***Bias-Variance Tradeoff*** !



## BIAS-VARIANCE TRADEOFF

Nota-se que o modelo desejado da **equação exata** se encontra entre os modelos de **ALTO BIAS** e de **ALTA VARIÂNCIA**.





## MATEMATICAMENTE

**ERRO TOTAL** (*cálculo da soma dos quadrados das distâncias*)

$$Err(x) = E \left[ (Y - \hat{f}(x))^2 \right]$$

**DECOMPOSIÇÃO DO ERRO EM BIAS-VARIANCE**

$$Err(x) = \underbrace{\left( E[\hat{f}(x)] - f(x) \right)^2}_{\text{BIAS}^2} + \underbrace{E \left[ \left( \hat{f}(x) - E[\hat{f}(x)] \right)^2 \right]}_{\text{VARIÂNCIA}} + \underbrace{\sigma^2}_{\text{ERRO INTRÍNSECO}}$$


**BIAS<sup>2</sup>**

**VARIÂNCIA**

**ERRO  
INTRÍNSECO**

## MATEMATICAMENTE

Graficamente...



## Complexidade Ótima do Modelo

AUMENTO DO BIAS É EQUIVALENTE À  
REDUÇÃO DA VARIÂNCIA

$$\frac{\text{Bias}}{\text{Complexidade}} = - \frac{\text{Variância}}{\text{Complexidade}}$$

## REFERÊNCIAS

EASTON, G. ***Bias vs. Variance Tradeoff, Cross-Validation, and Overfitting in Prediction (Part 1)***

<http://datasciencesource.com/bias-vs-variance-part-1/>

FORTMANN-ROE, S. ***Understanding the Bias-Variance Tradeoff***, 2012.

<http://scott.fortmann-roe.com/docs/BiasVariance.html>

FORTMANN-ROE, S. ***Accurately Measuring Model Prediction Error***, 2012.

<http://scott.fortmann-roe.com/docs/MeasuringError.html>

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. ***The Elements of Statistical Learning - Data Mining, Inference, and Prediction*** - 2nd, 2017.

[https://web.stanford.edu/~hastie/ElemStatLearn/printings/ESLII\\_print12.pdf](https://web.stanford.edu/~hastie/ElemStatLearn/printings/ESLII_print12.pdf)

KHAN ACADEMY. ***Biased and unbiased estimators from sampling distributions examples***, 2017.

<https://www.youtube.com/watch?reload=9&v=PK8aeeVx3io>

STARMER, J. ***Machine Learning Fundamentals: Bias and Variance***, StatQuest, 2018.

<https://www.youtube.com/watch?v=EuBBz3bl-aA>